

MLP 1 128 x 128

Accuracy

Evaluando el modelo se llegó a **52,2%** de accuracy.

Tamaño

No cuantizado: 8.225,25 KB

Cuantizado: 2MB

Número de operaciones

MACs: 2.105.472

FLOPs: 4.210.944

FPS $\approx$ 3,9 FPS

Energía $\approx$ 0,051 J/inferencia

Potencia = 0,299 W




Figura 1: Topología 1, MLP 128x128

Fuente: Netron

MLP 2 reducido 64 x 64

Accuracy

Evaluando el modelo se llegó a **54,2%** de accuracy.

Tamaño

No cuantizado: 1032,63 KB

Cuantizado: 256 KB

Número de operaciones

MACs: 532,608

FLOPs: 1.065.216

FPS $\approx$ 15 FPS

Energía $\approx$ 0,012 J/inferencia

Potencia = 0,299 W




Figura 2: Topología 2, MLP reducida 64x64

Fuente: Netron

CNN 1: Convoluciones Depth/Point wise para hacerlo más ligero

Accuracy

Se evaluó el mismo modelo y se llegó aproximadamente a un valor de **63.8% de accuracy** en test.

Tamaño

No cuantizado: 113,3 KB

Cuantizado: 11,95 KB

Máximo en RAM estimado: 120KB

Número de operaciones

MACs: 1.758.656

Ops: 3.517.312

FPS: 4 aprox

Energía: $0,299 \times 0,155 \text{ s} = 0,046 \text{ J/inferencia}$

Potencia: 0,299 W




Figura 3: Topología 3, CNN 128x128

Fuente: Netron

CNN 2: Convoluciones tradicionales

Accuracy

Se evaluó el mismo modelo 10 veces con el mismo dataset de validación llegando a un promedio de **81.7% de accuracy**.

Tamaño

No cuantizado: 61 KB

Cuantizado: 22 KB

Número de operaciones

MACs: 26.657.984

Ops: 53315968

FPS: 0,445

Energía: 0,299 W x 2,126 = 0,646 J/inferencia

Potencia: 0,299W




Figura 4: Topología 4, CNN 128x128 menos capas

Fuente: Netron

CNN 3: Convoluciones tradicionales con input reducido

Accuracy

Se evaluó el mismo modelo 10 veces con el mismo dataset de validación llegando a un promedio de **85.6% de accuracy**.

Tamaño

No cuantizado: 34 KB

Cuantizado: 15 KB

Número de operaciones

MACs: 1.628.768

Ops: 3.257.536

FPS: 7,46

Energía: 0,299 W x 0,134 s = 0,04 J/inferencia

Potencia: 0,299 W




Figura 5: Topología 5, CNN liviana y optimizada
Fuente: Netron

Tiempos de latencia por topología

MLP 1: 0,256 s

MLP 2: 0,066 s

CNN 1: 0,155 s

CNN 2: 2,126 s

CNN 3: 0,134 s

Gráficos




Figura 6: Gráfico accuracy vs tamaño

Fuente: Elaboración propia




Figura 7: Gráfico accuracy vs FPS

Fuente: Elaboración propia




Figura 8: Gráfico accuracy vs potencia

Fuente: Elaboración propia




Figura 9: Gráfico accuracy vs energía por inferencia

Fuente: Elaboración propia

Roofline Plot




Figura 9: Roofline Plot

Fuente: Elaboración propia

Análisis

Previo a realizar la discusión sobre qué modelo utilizar, vale destacar que todas las mediciones fueron realizadas bajo diversos parámetros específicos y supuestos. Primero, la frecuencia de operación del ESP32 S3 fue de 160 MHz, por lo que se podría lograr una mejora en algunos cálculos. Luego, como se solicitaba en el enunciado, fueron consideradas para los cálculos solo las capas de convolución y las *fully connected*. También, con el fin de simplificar los cálculos, se midió el tiempo de un solo MAC y de una búsqueda de memoria y luego estos tiempos se multiplicaron en base a los parámetros de cada modelo. Por último, como se pudo evidenciar en el laboratorio 1, se asumió la potencia de cada topología como la misma, o sea que se mantuvo constante. Se tomó el valor correspondiente para la frecuencia utilizada y se calculó la energía de cada modelo como medición extra. Con todo esto, se busca dar a explicar que se cumplió el objetivo del segundo punto del laboratorio que era una estimación de diversos valores de las topologías en la

ESP32 S3, lo cual se puede alejar levemente de las mediciones reales pero mantiene la idea principal.

Considerando lo anteriormente mencionado y los gráficos expuestos, es la topología número 5 o la CNN número 3 la cual demostró mejor comportamiento y resultados a lo largo de las diversas mediciones. Fue la que mejor *accuracy* obtuvo, tiene pequeño tamaño previo a cuantización, mantiene una cantidad suficiente de FPS y no tiene un gran consumo de energía. Esto deja espacio para seguir refinándola e ir modificando sus hiperparámetros para obtener mejores mediciones y resultados. Es por esto que se opta por usar esta topología pero considerando que puede seguir rindiendo mejor e incluso, si se presenta y utiliza un *dataset* mejor preparado, podría mejorar mucho su comportamiento.

Link repositorio GitHub con *dataset*

https://github.com/open-rajs/dataset_embbebidos_grupo8.git